PROJET RÉALISÉ PAR

L'ÉQUIPE INVESTIGATIONDATA DU GROUPE DE TD2

RAPPORT DE GROUPE DES UE BASES DE DONNÉES + SCIENCES DES DONNÉES 2

Abbassi Younes, Allaali Narjis, Bouguima Kawthar, Taghnakt Myriam



Département MIASHS, UFR 6 Informatique, Mathématique et Statistique
Université Paul Valéry, Montpellier 3

Mars 2026

Soumis comme contribution partielle
pour le cours Science des données 2 et Bases de données

Déclaration de non plagiat

Nous déclarons que ce rapport est le fruit de notre seul travail, à part lorsque cela est indiqué explicitement.

Nous acceptons que la personne évaluant ce rapport puisse, pour les besoins de cette évaluation :

- la reproduire et en fournir une copie à un autre membre de l'université ; et/ou,
- en communiquer une copie à un service en ligne de détection de plagiat (qui pourra en retenir une copie pour les besoins d'évaluation future).

Nous certifions que nous avons lu et compris les règles ci-dessus.

En signant cette déclaration, nous acceptons ce qui précède.

Signature : Abbassi Younes Date : 24/03/2026

Signature : Allaali Narjis Date : 24/03/2026

Signature : Bouguima Kawthar Date : 24/03/2026

Signature : Taghnakt Myriam Date : 24/03/2026

28 mars 2026

Remerciements

À compléter avant la remise du rapport.

Nos plus sincères remerciements vont à notre encadrant pédagogique pour les conseils avisés sur notre travail.

Nous remercions aussi ...

28 mars 2026

Résumé

L'image ci-dessous vous donne quelques conseils pour rédiger un bon résumé.

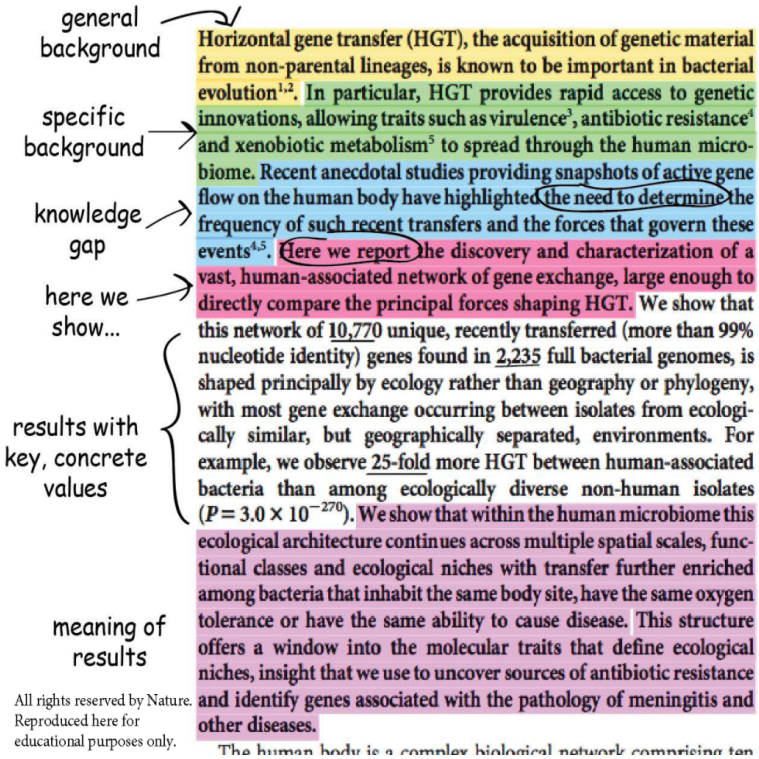


Table des matières

Chapitre 1 Introduction 1
1.1 Dossier d'ouverture . . . 1
1.2 Responsabilités et composition de l'équipe de recherche . . . 2

Chapitre 2 Collecte des preuves — Les données 3
2.1 Provenance des données . . . 3
2.2 Descriptif des tables . . . 4

Chapitre 3 Reconstitution du système — La base de données 5
3.1 Import des données . . . 6
3.2 Requêtes réalisées . . . 6
3.3 Quelques détails techniques . . . 6

Chapitre 4 Matériel et Méthodes 7
4.1 Logiciels . . . 7
4.2 Modélisation statistique . . . 7

Chapitre 5 Premiers indices — Analyse exploratoire 8
5.1 Utiliser R . . . 8

Chapitre 6 Mise à l'épreuve — Modélisation 10
6.1 La droite de régression linéaire : un premier exemple . . . 10

Chapitre 7 Interprétation — Résolution de l'enquête 11

Chapitre 8 Conclusion — Verdict 12

Bibliographie 13

Annexes 14
Codes . . . 14
Tables . . . 14

Chapitre 1

Introduction

1.1 Dossier d'ouverture

Au cours des dernières années, la criminalité organisée est devenue un enjeu majeur à l'échelle internationale. Les différences observées entre les pays en termes de taux de criminalité soulèvent des interrogations quant aux facteurs pouvant expliquer ces variations. Parmi ces facteurs, les conditions socio-économiques telles que le niveau de revenu, le chômage ou encore les inégalités sociales semblent jouer un rôle déterminant.

Dans le cadre de ce projet, Narjis, Kawthar, Myriam ainsi que Younes ont été missionnés par INTERPOL (a modifier en cas de non droit) afin de mener une enquête sur les causes de la criminalité à l'échelle mondiale. Cette mise en situation permet d'aborder l'analyse de manière concrète, en mobilisant des données réelles pour répondre à une problématique actuelle.

Dans quelle mesure les facteurs socio-économiques influencent-ils le taux de criminalité organisée entre pays a l'échelle l'internationale ?

Cette question est particulièrement importante pour les décideurs publics et les organisations internationales, car une meilleure compréhension de ces relations pourrait permettre de mettre en place des politiques de prévention plus efficaces et adaptées aux réalités de chaque pays.

Ce projet s'inscrit dans le cadre des enseignements de bases de données (TE43MI) et de sciences des données (TE44MI). Il repose sur l'analyse de différentes bases de données afin d'identifier les facteurs explicatifs de la criminalité et d'évaluer leur impact.

1.2 Responsabilités et composition de l'équipe de recherche

Nom	Statut et id	Missions principales
ABBASSI Younes	Étudiant n°22401320	Responsable de la table PAYS (création, harmonisation, contrôles SQL) et co-responsable des analyses descriptives R sur la répartition des pays.
ALLAALI Narjis	Étudiante n°22313109	Responsable de la table INDICATEURS année 2 et des comparaisons temporelles (SQL + préparation des données) et co-responsable des analyses R comparatives.
BOUGUIMA Kawthar	Étudiante n°22303487	Responsable de la table CRIMINALITÉ et de la table finale d'analyse (jointures SQL) et co-responsable des analyses R (corrélations et régressions).
TAGHNAKT Myriam	Étudiante n°	Responsable de la table INDICATEURS année 1 (collecte, nettoyage, intégration SQL) et co-responsable des analyses statistiques R et corrélations.

Chapitre 2

Collecte des preuves — Les données

2.1 Provenance des données

Nous avons utilisé plusieurs sources de données internationales afin d'analyser l'influence des facteurs socio-économiques sur la criminalité.

Les principales sources utilisées sont :

— Données de criminalité organisée :
`https://ocindex.net/downloads`
— Données socio-économiques (PIB, chômage, urbanisation) :
`https://perspective.usherbrooke.ca`
— Données d'Indice de Développement Humain (IDH) :
`https://hdr.undp.org/data-center`

Ces données sont disponibles sous forme de fichiers `CSV/XLSX` ainsi que code `.R`

À partir des jeux de données initiaux, nous avons construit trois tables principales :

— une table `PAYS`
— une table `INDICATEURS`
— une table `CRIMINALITE`

Les données étant réparties dans plusieurs fichiers, nous avons regroupé les indicateurs socio-économiques (PIB, chômage, IDH, urbanisation) dans une seule table.

Afin de réduire le périmètre du projet, nous avons effectué les filtrages suivants :

Au niveau des colonnes nous avons conservé uniquement les variables pertinentes :

— PIB par habitant
— taux de chômage
— taux d'urbanisation
— IDH
— indice de criminalité

Les autres variables ont été supprimées car non pertinentes pour l'analyse.

Pour ce qui est des lignes nous avons conservé

— les pays avec des données disponibles pour **2017 et 2023** (155 pays)
— les observations avec aucune valeurs manquantes

La population étudiée correspond à un ensemble de pays pour lesquels les données sont disponibles sur les deux années étudiées.

L'unité statistique est le couple (`pays, année`)

Chaque ligne correspond donc à un pays pour une année donnée.

Ces données permettent d'analyser les liens entre **indicateurs socio-économiques et criminalité**, et ainsi d'apporter des éléments de réponse aux problématiques posées.

2.2 Descriptif des tables

Table 2.1 : Pays (156 x 3)

nom_colonne	Type	Signification	Caractéristiques
id_pays	CHAR(3)	Code ISO	Clé étrangère
annee	INT	Année d'enregistrement des données	Non unique
indice_criminalite	FLOAT	Indice de criminalité	Allant de 1 à 10

Table 2.2 : Criminalité (311 x 3)

nom_colonne	Type	Signification	Caractéristiques
id_pays	CHAR(3)	Code ISO	Clé primaire
nom_pays	VARCHAR	Nom du pays	Unique
region	VARCHAR	Région géographique	19 régions

Table 2.3 : Indicateurs (311 x 6)

nom_colonne	type	Signification	Caractèristique
id_pays	CHAR(3)	Code ISO	Clé etrangère
année	INT	Année d'observation	Non unique
PIB	FLOAT	Produit interieur brut par habitant	Valeurs positives
chomage	FLOAT	Taux de chomage en %	Entre 0 et 100
IDH	FLOAT	Indice de développement humain	Entre 0 et 1
urbanisation	FLOAT	% population urbaine	Entre 0 et 100

Les variables sélectionnées permettent d'analyser l'influence de plusieurs facteurs socio-économiques sur le niveau de criminalité.

Les indicateurs économiques (PIB, chômage), sociaux (IDH) et structurels (urbanisation) sont utilisés comme variables explicatives, tandis que l'indice de criminalité constitue la variable à expliquer.

Cette structuration des données permet d'effectuer des analyses statistiques, afin de répondre à la question de recherche.

Chapitre 3

Reconstitution du système — La base de données

— Le modèle conceptuel de données a été construit afin de représenter les relations entre les pays, les indicateurs socio-économiques et le niveau de criminalité.

L'entité centrale du modèle est **le pays**, pour lequel plusieurs observations peuvent être enregistrées en fonction des années étudiées (2017 et 2023).

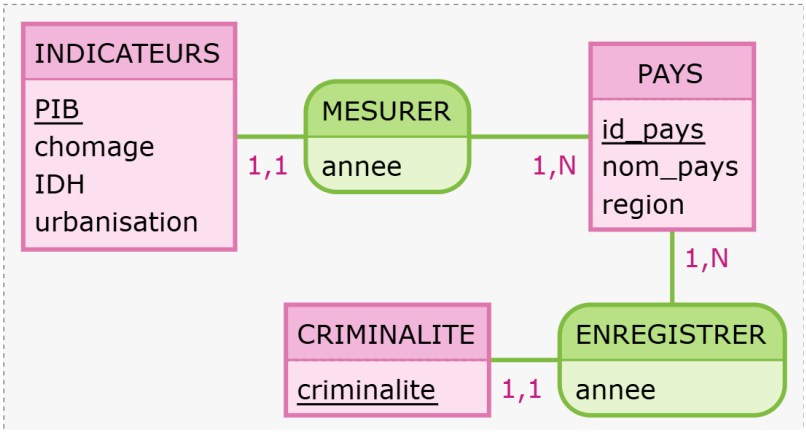


Figure 3.1: MCD réalisée à l'aide de l'outil MOCODO

— Le modèle relationnel de données est obtenu à partir du MCD en traduisant les entités en tables relationnelles.

Les relations sont implémentées à l'aide des clés étrangères `id_pays` ainsi qu'`annee` , permettant de relier les tables entre elles.

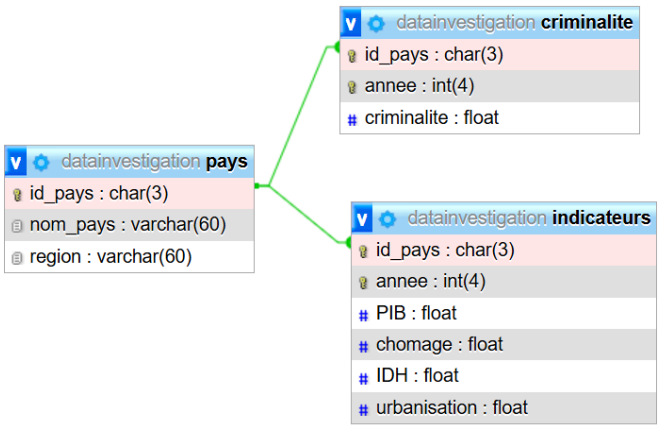


Figure 3.2: MOD réalisée à l'aide du designer de PhpMyAdmin

3.1 Import des données

- Préciser les nettoyages réalisés avant l'import comme l'uniformisation des valeurs des champs (*e.g.*, Mr, M., Monsieur, ...) ou le remplissage des valeurs manquantes par une valeur moyenne ...
- Source de données 1 :
  - Suppression des colonnes XXX, car XXX
  - Suppression des doublons dans les colonnes XXX
  - Filtrage en fonction de la colonne XXX, nous n'avons conservé que...

3.2 Requêtes réalisées

Pour chaque requête, l'exprimer en langage naturel puis en SQL. Puis donner le résultat obtenu (ou un extrait) et expliquer ce résultat.

L'objectif est de varier le type de requêtes et de répondre à votre problématique initiale.

3.3 Quelques détails techniques

On peut interagir avec une base de données directement depuis RMarkdown : i.e. requêter puis récupérer et afficher le résultat directement depuis le .Rmd. Un fichier connexionBDD.Rmd est fourni pour donner des exemples.

Chapitre 4

Matériel et Méthodes

4.1 Logiciels

Lister tous les logiciels utilisés pour la partie statistique du rapport (et également ceux pour gérer et communiquer entre les membres du projet s'il y en a en particulier)

R (ou Python) est le logiciel à privilégier pour la Science des Données. Pour assurer une reproductibilité maximale, vous devriez utiliser R Markdown (ou un Notebook Jupyter, et éventuellement un outil de gestion des versions tel que `Git`), par exemple via Google Colab ou RStudio dans les nuages. Évitez d'utiliser Word !

Il est de votre responsabilité de donner les versions des logiciels que vous utilisez, ainsi que de donner des informations techniques sur l'ordinateur qui vous a servi pour les analyses (système d'exploitation, vitesse du processeur, etc.). Penser à fournir des citations pour les logiciels utilisés, par exemple [1].

4.2 Modélisation statistique

Quels outils ou méthodes de statistiques allez-vous utiliser ? Donner des équations mathématiques s'il y a lieu et lister les éventuels présupposés («assumptions» en anglais) que vous devez faire sur les données afin d'utiliser ces outils ou méthodes (*e.g.*, normalité, absence de valeurs aberrantes, etc.).

Il est également bon d'indiquer quelles sont les avantages et les limites de ces méthodes.

Vous pourrez consulter avec profit les Chapitre 11–13 du livre sur R :
http://biostatisticien.eu/springeR/livreR.pdf

1. L'entrée BibTeX ajoutée dans le fichier `references.bib` a été obtenue grâce à la commande `citation(package = "tidyverse")` tapée dans la console de R.

Chapitre 5

Premiers indices — Analyse exploratoire

Toute étude impliquant des données doit **obligatoirement** inclure une analyse exploratoire préalable. Celle-ci permet de mieux comprendre l'information contenue dans les données.

Il faut produire de nombreux résumés graphiques (*e.g.*, histogrammes, nuages de points, boxplots, etc.) et numériques (*e.g.*, médiane, moyenne, variance, etc.). Ainsi, il faut faire une analyse descriptive uni- et bivariée systématique de toutes les variables du jeu de données. Puis, il faut uniquement conserver les plus pertinents (les autres pouvant être gardés en Annexe), c'est-à-dire ceux qui permettront de dégager des éléments de réponse pour la question de recherche envisagée. Chaque figure et tableau doit être commenté. Mais il ne faut pas extrapoler et dire des choses qui ne sont pas visibles dans ces graphiques ou tableaux. Pour chaque analyse, vous pourrez préciser le nombre d'individus/ d'unités statistiques concernés au total.

Vous pourrez consulter avec profit le Chapitre 9 du livre sur R :
http://biostatisticien.eu/springeR/livreR.pdf

5.1 Utiliser R

Il est facile d'inclure des codes R dans votre rapport, qui seront exécutés à la volée (*i.e.*, lors de la traduction de votre fichier `Rmd` en fichier `PDF` ou `DOC`). Par exemple :

```
boxplot(cars, col = c("#5975a4", "#cc8963"))
```

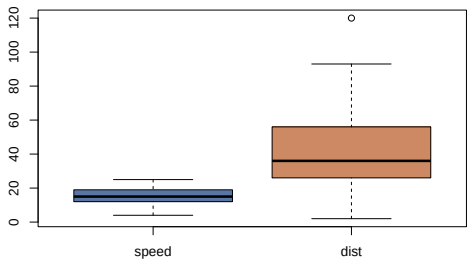


Figure 5.1: Deux boxplots.

```
colMeans(cars)
```

```
## speed  dist
## 15.40 42.98
```

Les lignes de code ne doivent pas dépasser dans la marge de droite. Ainsi on pourrait remplacer le chunk ci-dessous :

```r
boxplot(cars, main = "Un titre qui est vraiment beaucoup trop long et qui dépasse dans
```

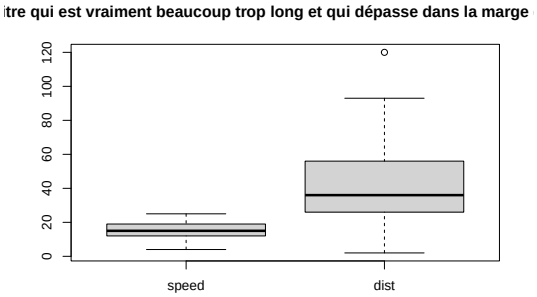


FIGURE 5.2: Pas super.

par celui-ci :

```r
boxplot(cars,
        main = "Un titre qui est vraiment beaucoup trop long\n mais qui ne dépasse plus dans la marge de droite")
```

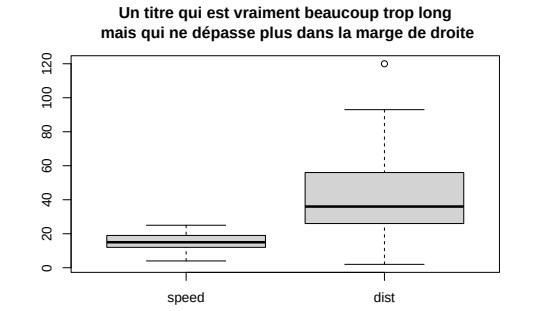


FIGURE 5.3: Déjà mieux.

où l'on a :
— utilisé la commande LaTeX `\tiny` pour changer la taille de la police (suivi de de `\normalsize` pour revenir à la taille normale),
— mis l'instruction `main = ...` sur la deuxième ligne,
— utilisé `\n` pour afficher le titre sur deux lignes.

Remarques : Contrairement aux graphiques précédents, nous vous demandons, pour effectuer les graphiques, d'utiliser le package `ggplot2`. Voir https://juba.github.io/tidyverse/08-ggplot2.html pour une courte introduction.

Chapitre 6

Mise à l'épreuve — Modélisation

Dans cette partie, vous pourrez utiliser les outils et méthodes vus au semestre précédent pour analyser les liens entre les variables.

Pour cela, vous pourrez utiliser les tests du χ^2, test du coefficient de corrélation linéaire, test d'Anova, la droite de régression linéaire.

Vous pourrez également proposer des modèles pour faire du clustering (k-means, CAH), de la classification (K plus proches voisins par exemple) comme vu en Science des données 1.

6.1 La droite de régression linéaire : un premier exemple

Si on souhaite expliquer les variations d'une variables réponse Y en fonction d'un certain nombre de prédicteurs $x_1, \ldots, x_p$, on peut utiliser un modèle de régression linéaire simple ($p = 1$) ou multiple ($p > 1$)

$$Y_i = \beta_0 + \beta_1 x_{1i} + \cdots + \beta_p x_{pi} + \epsilon_i, \qquad i = 1, \ldots, n.$$

où l'on présuppose que les ϵ_i sont i.i.d. $N(0, 1)$ pour tout $i = 1, \ldots, n$ (n étant la taille de l'échantillon).

Vous pourrez toujours consulter avec profit les Chapitre 11–13 du livre sur R :
http://biostatisticien.eu/springeR/livreR.pdf
Ces chapitres détaillent l'utilisation de certains tests et modèles sous `R`.

Chapitre 7

Interprétation — Résolution de l'enquête

Placer les résultats que vous avez obtenus dans le chapitre précédent en perspective par rapport au problème étudié.

Chapitre 8

Conclusion — Verdict

Quelles sont les conclusions principales ? Quelles sont vos recommandations pour le commanditaire ? Quelles analyses subséquentes pourraient être faites dans le futur ?

On attend de vous deux types de perspectives : des perspectives à court terme pour améliorer rapidement votre approche et des perspectives à plus long terme qu'elles soient liées à la science des données ou au domaine métier pour lequel vous avez travaillé.

Lister également les difficultés rencontrées dans la partie BD (e.g., taille de la base, manque de données, ...) et dans la partie statistique.

Bibliographie

Annexes

Il faut utiliser les annexes de façon judicieuse. C'est ici que l'on place des résultats trop volumineux pour apparaître dans le corps du rapport. Ou bien des résultats (e.g., graphiques) moins intéressants que les autres. Cela permet de limiter le nombre de pages du coeur du rapport, et d'ajouter des détails dans cette partie pour le lecteur désireux d'en savoir plus.

Codes

Ajouter vos codes informatique ici. Les codes doivent être correctement indentés et commentés.

Tables

Si vous avez des tableaux supplémentaires, vous pouvez les ajouter ici.

Utiliser https://www.tablesgenerator.com/markdown_tables pour créer des tables Markdown simples, ou bien utiliser LaTeX.

1. Table Markdown

Table 8.1: une légende au-dessus du tableau.

Les tables	sont	cool
col 1 est	alignée à gauche	$1600
col 2 est	centrée	$12
col 3 est	alignée à droite	$1

Aligner les nombres de la troisième colonne sur la droite permet d'afficher les unités au-dessus des unités, les dizaines au-dessus des dizaines, etc. Il faut toujours privilégier cette présentation.

2. Table Latex

Table 8.2: une légende au-dessus du tableau

Les tables	sont	cool
col 1 est	alignée à gauche	1600
col 2 est	centrée	12
col 3 est	alignée à droite	1

Remarques

— {lcr} : gauche (l), centré (c), droite (r)
— `\caption` place la légende au-dessus
— `\label` permet de référencer le tableau (`\ref{tab7.1}`)
— Les nombres sont bien alignés à droite dans la 3e colonne